TÀI LIỆU NGHIÊN CỨU CoRAG (Chain of Retrieval Augmented Generation)

I. GIỚI THIỆU

RAG (Retrieval Augmented Generation) là kiến trúc phổ biến giúp mô hình ngôn ngữ lớn (LLM) trả lời dựa trên dữ liệu bên ngoài như Vector Database hoặc BM25. Tuy nhiên, RAG truyền thống chỉ thực hiện truy xuất (retrieve) một lần dựa trên câu hỏi gốc.

Điều này dẫn đến rủi ro lớn: nếu câu hỏi thiếu ý hoặc diễn đạt không đầy đủ, hệ thống sẽ truy xuất sai tài liệu và LLM sẽ tạo ra câu trả lời sai.

CoRAG (Chain of Retrieval Augmented Generation) được đề xuất để giải quyết vấn đề này bằng cách thực hiện nhiều lượt truy xuất dựa trên chuỗi suy luận từ câu hỏi.

II. FLOW TỔNG THỂ RAG VS CoRAG

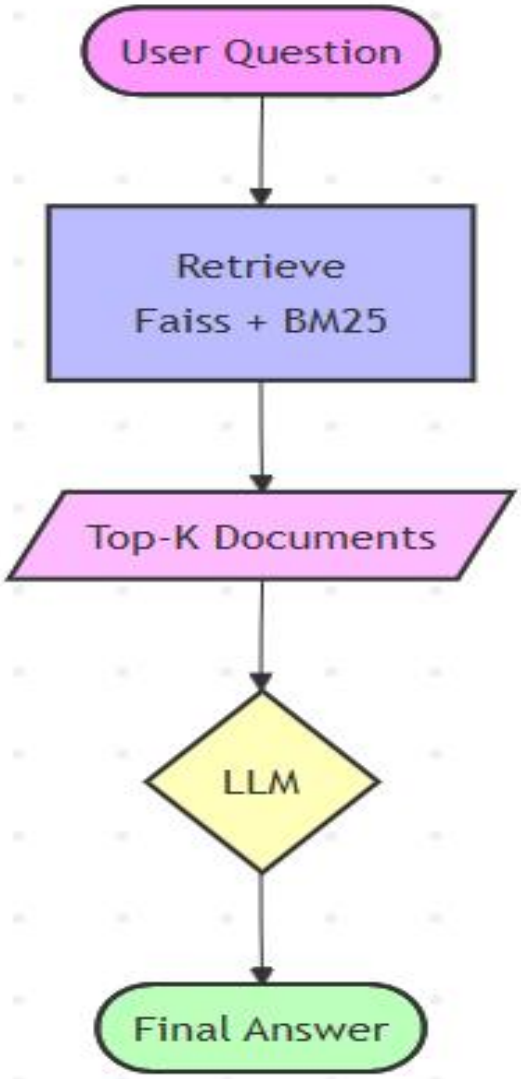
User Question
Retrieve
Faiss + BM25
Top-K Documents
LLM
Final Answer

Vấn đề: nếu bước retrieve sai → toàn bộ pipeline sai.

Trường hợp dùng RAG

Bước retrieve (1 lần)

Hệ thống dùng:

- FAISS
- BM25

để tìm tài liệu theo câu hỏi gốc.

Question → Retrieve → Top 5 documents

Vấn đề xảy ra

Do câu hỏi chứa từ **"từ chối"**, hệ thống ưu tiên lấy các đoạn nói về:

- reject reason
- trạng thái rejected

Nhưng **không lấy** đoạn nói về:

- role có quyền reject

Kết quả LLM trả lời

LLM chỉ đọc được tài liệu về *lý do bị từ chối*.

→ Trả lời thiếu: **không biết ai có quyền từ chối**.

CoRAG:

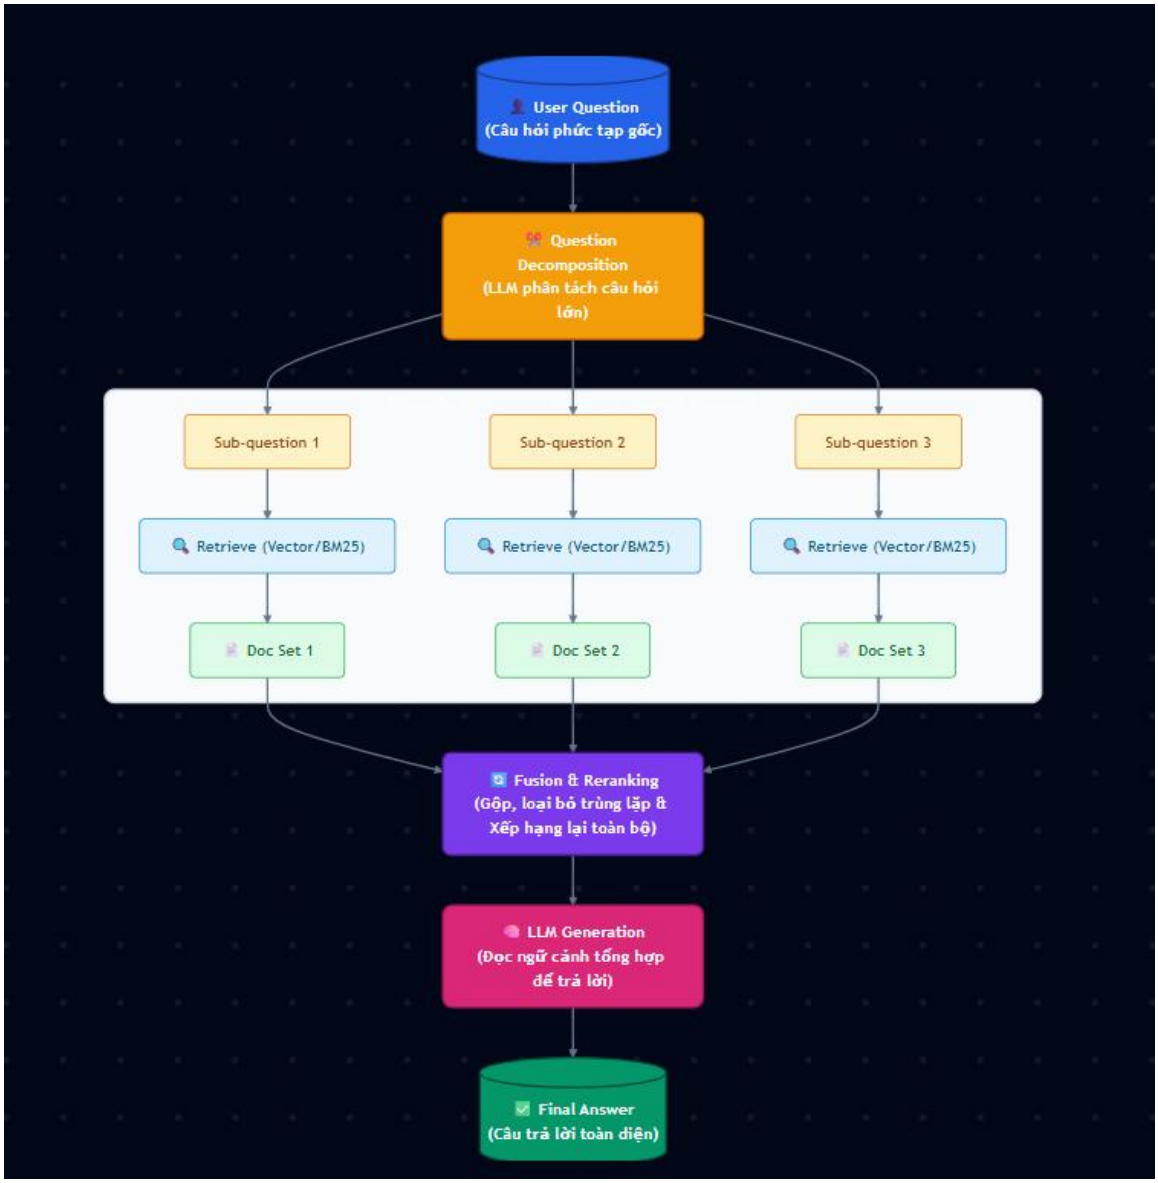

Trường hợp dùng CoRAG

Bước 1 – Question Decomposition

LLM tách thành:

Q1: Certificate bị từ chối trong những trường hợp nào?
Q2: Vai trò nào trong hệ thống có quyền từ chối Certificate?

Bước 2 – Retrieve nhiều lượt

Q1 → Retrieve → Doc A (reject conditions)
Q2 → Retrieve → Doc B (role permissions)

Bước 3 – Fusion & Rerank

Gộp A và B → chọn context tốt nhất.

Kết quả LLM trả lời

LLM đọc được:

Điều kiện reject

Role có quyền reject

→ Trả lời đầy đủ cả 2 ý.

III. PIPELINE THỰC THI CHI TIẾT

RAG:

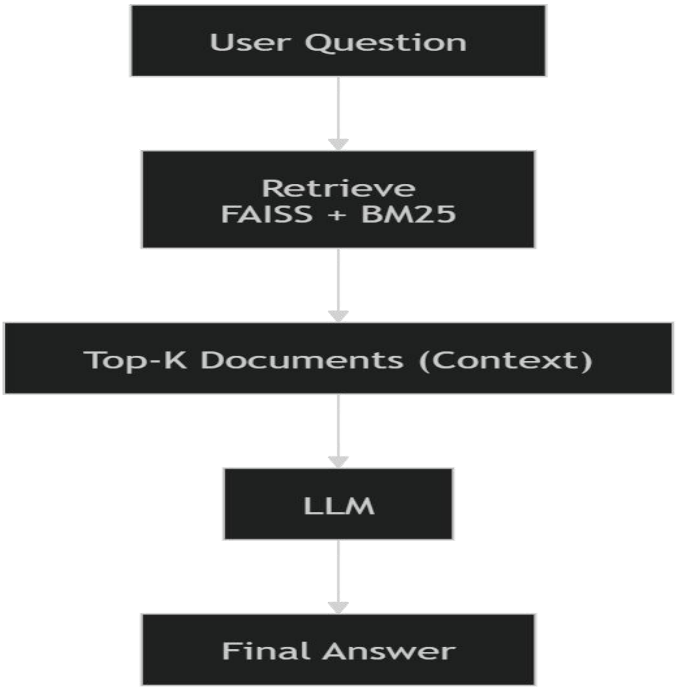
User Question
Retrieve
FAISS + BM25
Top-K Documents (Context)
LLM
Final Answer

CoRAG:

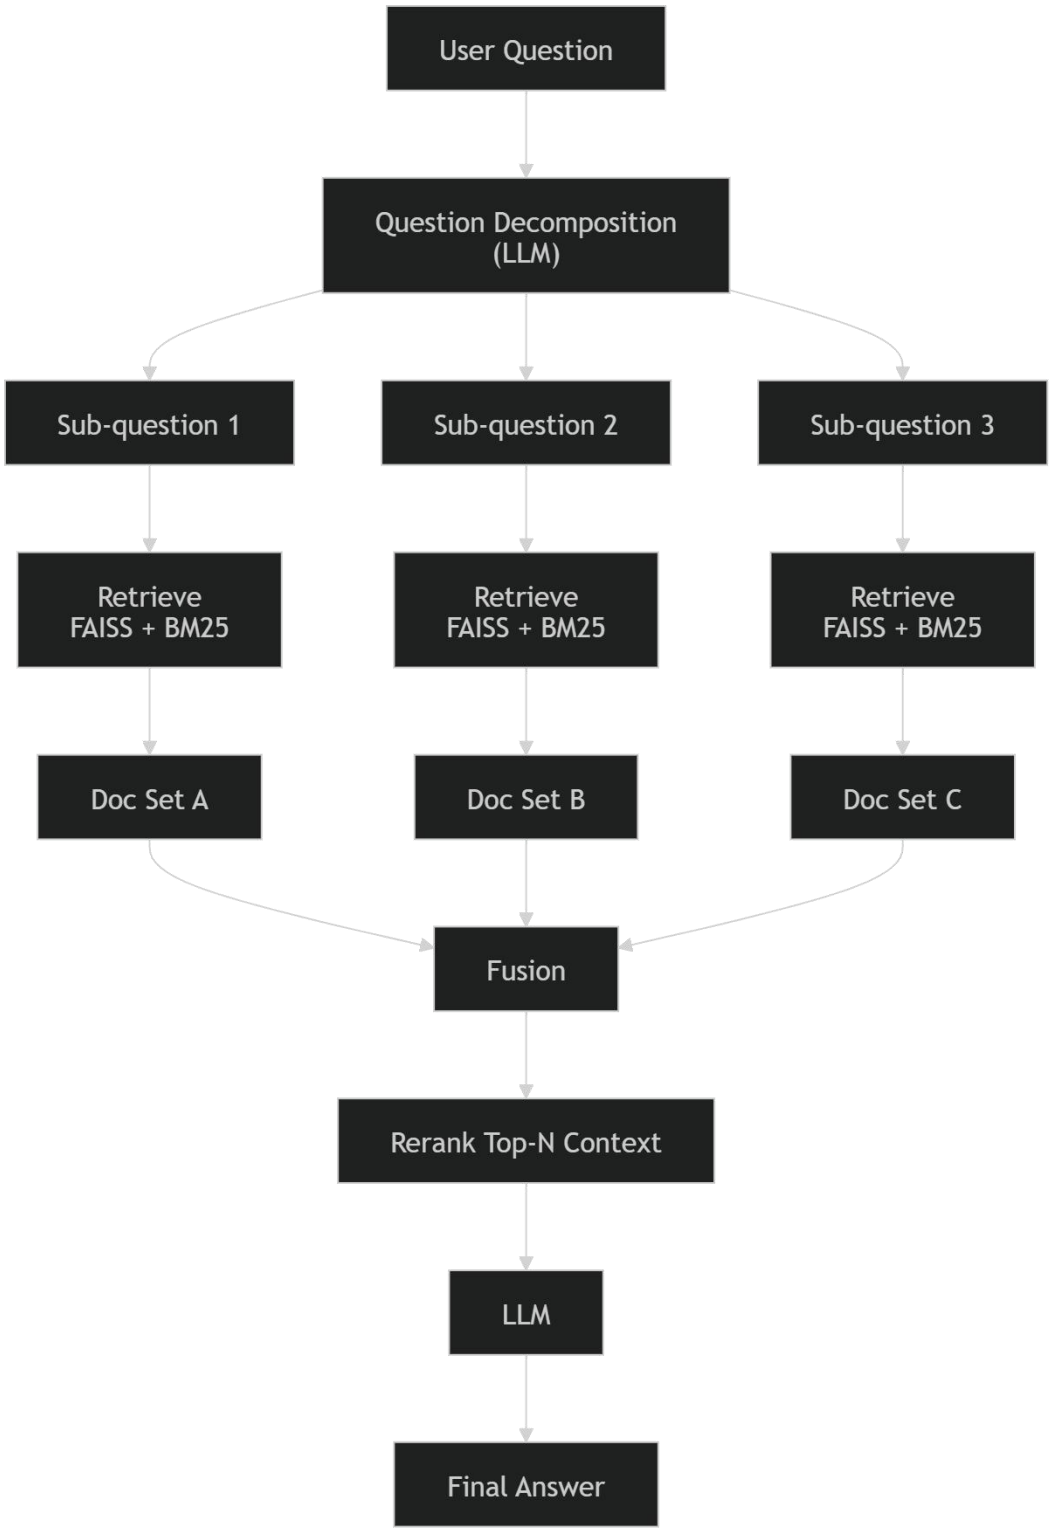

IV. SƠ ĐỒ CHI TIẾT CoRAG

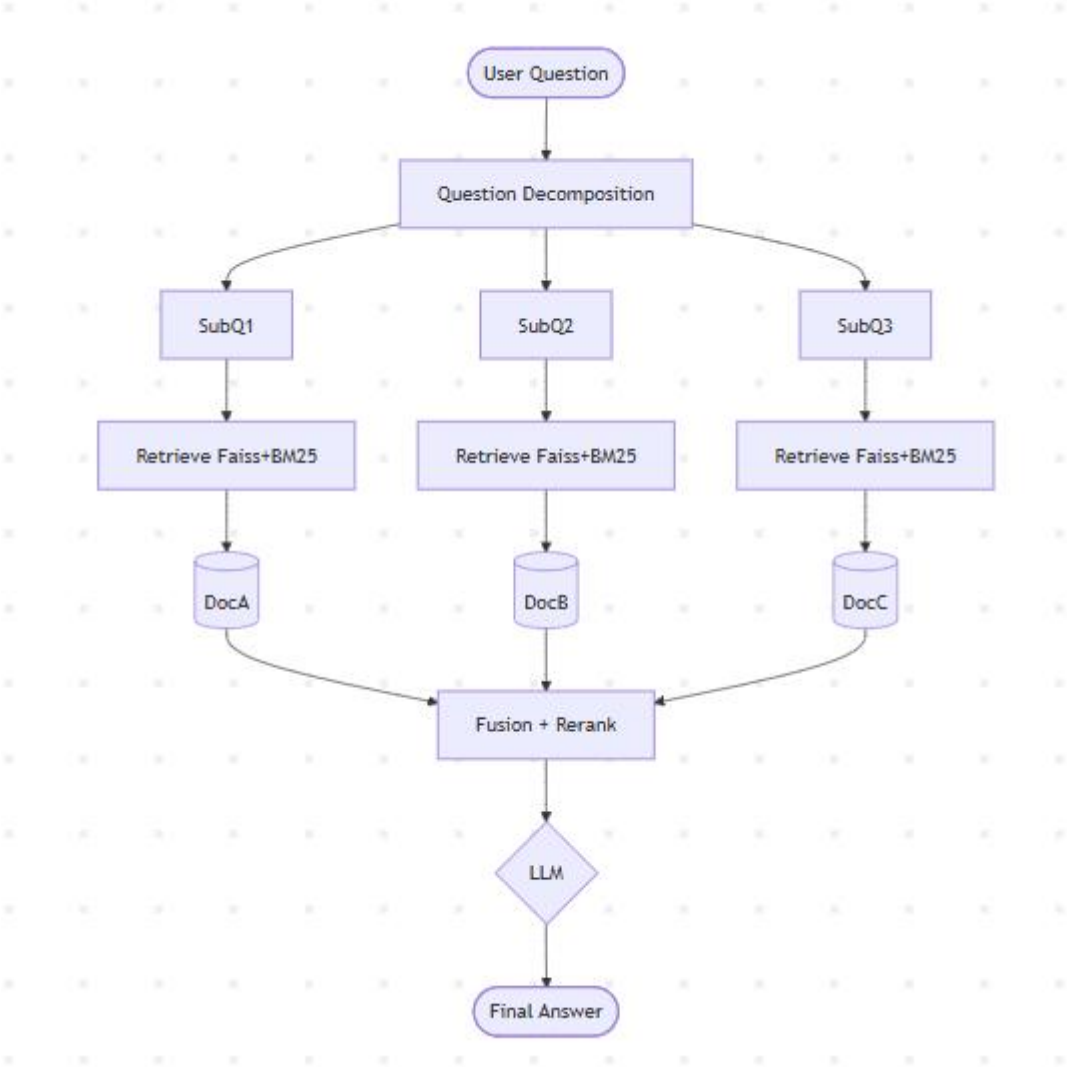

V. ĐIỂM KHÁC BIỆT GIỮA RAG VÀ CoRAG

Tiêu chí	RAG	CoRAG
Số lần retrieve	1	N lần
Phụ thuộc câu hỏi gốc	Rất cao	Thấp
Bao phủ thông tin	Hẹp	Rộng
Độ chính xác	Trung bình	Cao
Khả năng trả lời câu hỏi	Kém	Tốt

phức tạp		
Context đưa vào LLM	Một cụm doc	Doc đã fusion nhiều nguồn

VI. VÌ SAO CoRAG HIỆU QUẢ

RAG

- Câu hỏi thiếu ý → Retrieve lệch → LLM trả lời sai

CoRAG

- LLM tự hiểu câu hỏi còn thiếu gì → tự tạo sub-question → retrieve bổ sung.

VII. KẾT LUẬN

CoRAG không thay đổi công nghệ retrieve (vẫn Faiss + BM25) mà thay đổi pipeline xử lý trước khi retrieve, giúp tăng độ chính xác rõ rệt trong hệ thống hỏi đáp trên tài liệu nghiệp vụ hoặc codebase.

VIII. HƯỚNG PHÁT TRIỂN

- Bổ sung Reranker (Cross-encoder)
- Loại bỏ tài liệu trùng lặp
- Áp dụng vào hệ thống hỏi đáp tài liệu nội bộ